Rakamin Academy x HOME CREDIT

Credit Risk Prediction: Balancing Financial Inclusion and Risk Mitigation

Membangun Model Klasifikasi Regonal Linear vs LightGBM untuk Optimasi Keputusan Kredit

Presented By:

Niqa Nabila Nur Ihsani

Rakamin Academy x HOME CREDIT

Latar Belakang

PT Home Credit Indonesia adalah **perusahaan pembiayaan** multiguna multinasional **yang melayani** lebih dari 3,4 juta **pelanggan untuk pembiayaan instan secara online maupun offline**. **Dengan volume pengajuan kredit yang sangat masif setiap harinya**, **sistem evaluasi kredit konvensional perusahaan rentan menghasilkan False Positive**, **yaitu keliru menolak nasabah potensial yang sebenarnya layak mendapat pinjaman**. Kondisi ini membuat perusahaan berisiko kehilangan peluang pendapatan yang signifikan dan kesulitan mengoptimalkan parameter pinjaman yang tepat sasaran demi kelancaran pelunasan.

Research Problem

Sistem evaluasi kredit konvensional rentan menghasilkan False Positive, sehingga berisiko menolak nasabah potensial dan belum mampu mengoptimalkan parameter pinjaman (principal, tenor, jadwal bayar) untuk meningkatkan keberhasilan pelunasan.

Business Understanding & Project Objectives

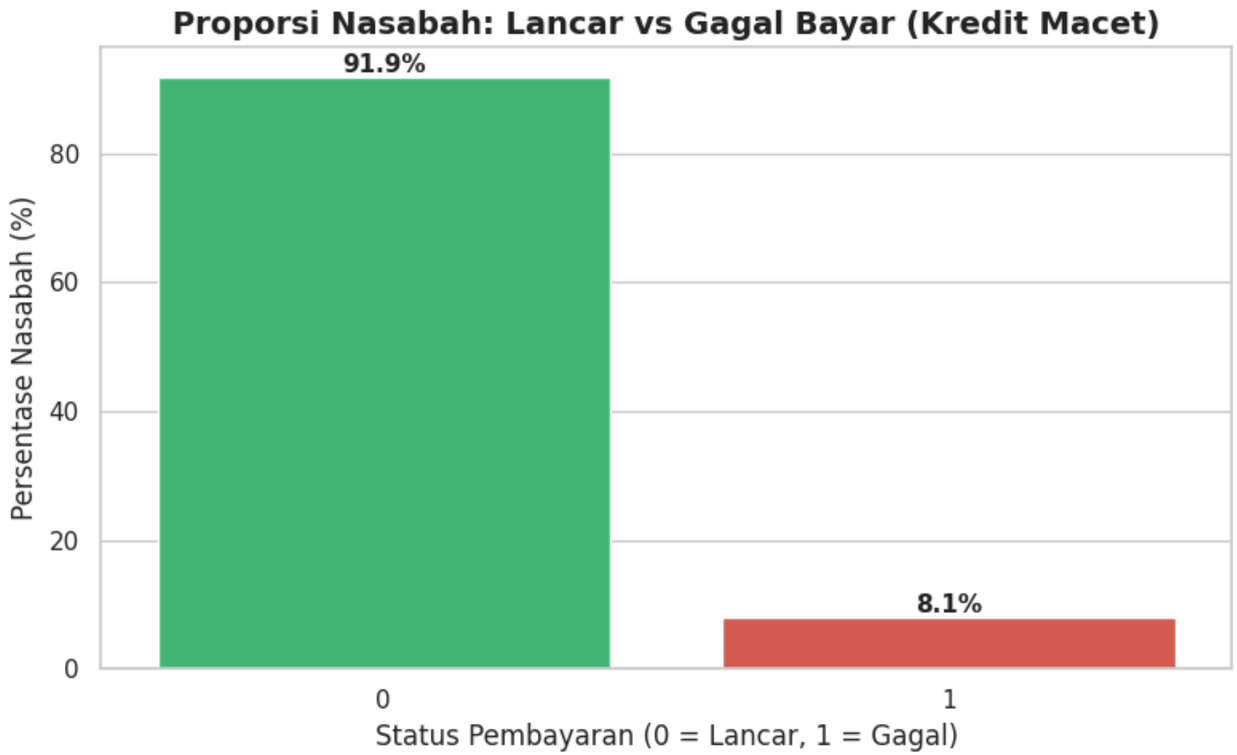

Karakteristik Data:

Distribusi kelas pada data historis sangat timpang (Highly Imbalanced Dataset), **didominasi oleh Target 0/Lancar sebesar 92%** (Kelas Mayoritas), dibandingkan **Target 1 / Gagal Bayar sebesar 8%** (Kelas Minoritas).

Objectives:

- **Mengembangkan dan membandingkan model klasifikasi** Machine Learning **untuk mengidentifikasi risiko nasabah secara akurat**.
- **Mengurangi** False Positive, yaitu **penolakan terhadap nasabah yang sebenarnya layak kredit**.
- Memanfaatkan probabilitas prediksi model untuk merancang parameter pinjaman yang dipersonalisasi (principal, tenor, cicilan).
- Meningkatkan keberhasilan pelunasan tanpa meningkatkan Non-Performing Loan (NPL).

Metrik Penelitian:

- **Akurasi** tidak digunakan karena **tidak representatif pada data class imbalance**.
- **Diterapkan class weighting** (misalnya is_unbalance=True pada LightGBM) **untuk memberi penalti lebih besar pada kelas minoritas**. Hal ini dilakukan **untuk membuat model lebih sensitif mendeteksi nasabah berisiko** (Recall meningkat).
- Untuk mencegah terlalu banyak False Positive (nasabah baik ikut ditolak), evaluasi difokuskan pada:
  a. PR-AUC → Menjaga trade-off antara Recall dan Precision pada kelas minoritas.
  b. ROC-AUC → Menilai kemampuan model membedakan tingkat risiko nasabah.

Ringkasan Data

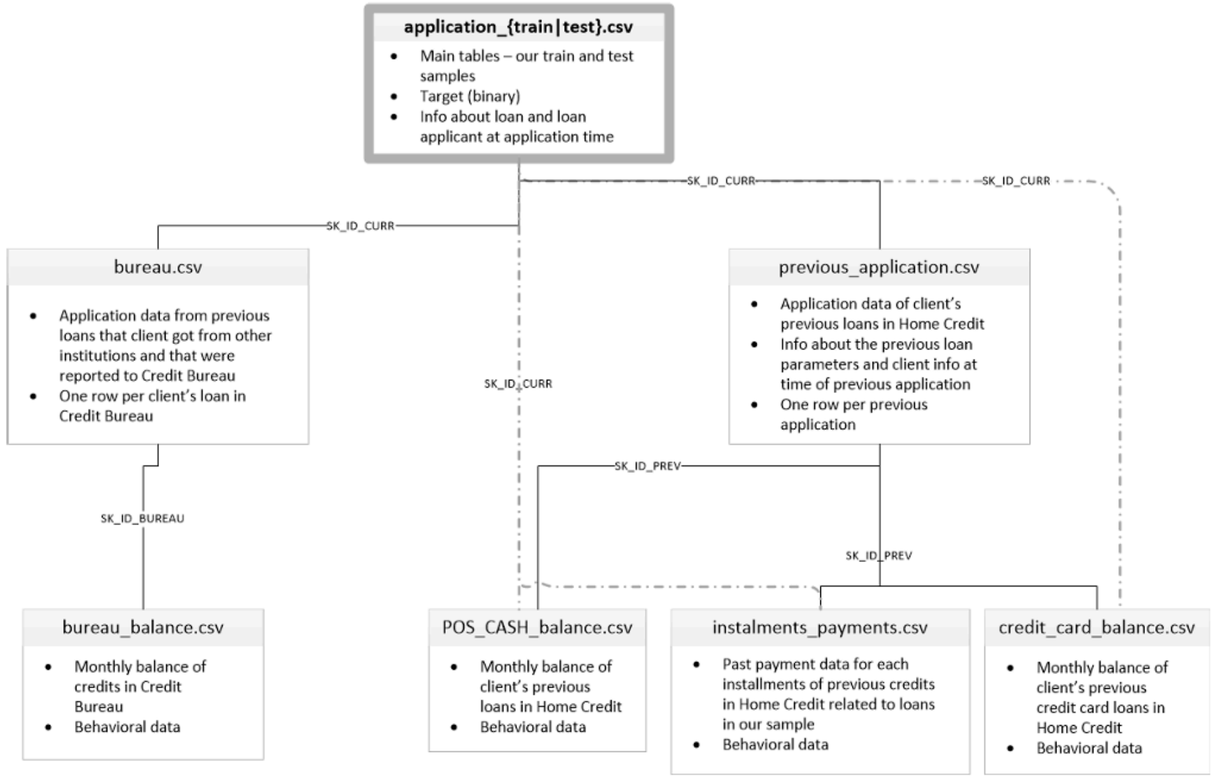

1. **Data Eksternal (Riwayat Biro Kredit)**

- **File**: bureau.csv dan bureau_balance.csv.
- **Deskripsi**: Merekam data pinjaman nasabah sebelumnya dari institusi keuangan lain yang dilaporkan ke Biro Kredit. Informasi ini dilengkapi dengan data perilaku (behavioral data) berupa saldo bulanan pinjaman tersebut.

1. **Tabel Utama (Core Data)**

- **File**: application_{train|test}.csv.
- **Deskripsi**: Tabel utama yang memuat sampel data train dan test. Tabel berisi informasi tentang pinjaman dan nasabah pada saat pengajuan, serta memuat variabel Target biner.
- **Kunci Relasi**: Menggunakan SK_ID_CURR untuk terhubung dengan tabel lainnya.

1. **Data Internal (Riwayat Nasabah)**

- **File Induk**: previous_application.csv.
- **Deskripsi**: Mencatat informasi parameter dan data aplikasi nasabah dari pinjaman sebelumnya di perusahaan.
- **Data Perilaku Bulanan**: Rincian riwayat dari pinjaman perusahaan masa lalu ini dihubungkan melalui SK_ID_PREV ke tiga tabel detail:
  - **POS_CASH_balance.csv**: Data saldo bulanan untuk pinjaman tunai dan point of sales (POS).
  - **credit_card_balance.csv**: Data saldo bulanan kartu kredit nasabah.
  - **installments_payments.csv**: Data riwayat pembayaran masa lalu untuk setiap cicilan pinjaman.

Data Pre-Processing

1. **Penghapusan data yang memiliki >60% parameter kosong**

   Menghapus 17 kolom (mayoritas terkait profil bangunan/tempat tinggal) yang memiliki data kosong di atas 60% agar tidak menimbulkan noise pada model.

2. **Penghapusan Nilai Duplikat**

   Memvalidasi integritas data (tidak ditemukan adanya baris ganda berdasarkan ID Nasabah/SK_ID_CURR).

3. **Konsistensi Data & Penanganan Anomali**

- Mengonversi format waktu (kolom DAYS_) menjadi angka absolut (positif).
- Mengganti nilai yang tidak masuk akal (seperti masa kerja 365243 hari (>100thn)) dengan angka 0, asumsi status pengangguran/pensiunan.
- Mengganti nilai teks terselubung (seperti 'XNA', 'not specified') menjadi N/A.

4. **Strategi Imputasi (Pengisian N/A):**

- Data Kategorikal (Teks): Secara umum diisi dengan kategori baru 'Unknown'. (Khusus anomali pada kolom Gender, diisi dengan nilai Modus-nya yaitu 'F').
- Data Numerik Spesifik (DAYS_EMPLOYED): Diisi dengan angka 0 (diasumsikan merepresentasikan status pengangguran/pensiun).
- Data Numerik Umum: Diisi menggunakan nilai tengah (Median). Selain itu, dibuatkan kolom indikator khusus (_IS_MISSING flag) agar model tetap mengenali bahwa data tersebut aslinya kosong.

Data Transform

1. **Data Splitting (80:20)**

   Membagi application_train yang memiliki data kolom TARGET lengkap dengan data pengujian menggunakan teknik Stratified Sampling untuk memastikan rasio ketimpangan risiko (8% gagal bayar) tetap konsisten di kedua set data.

2. **Feature Scaling**

- Menyeragamkan rentang skala seluruh fitur numerik (Standardization) agar model linier tidak bias terhadap nominal besar, dilakukan dengan ketat untuk mencegah kebocoran data (data leakage) ke test set.

Machine Learning Implementation and Evaluation

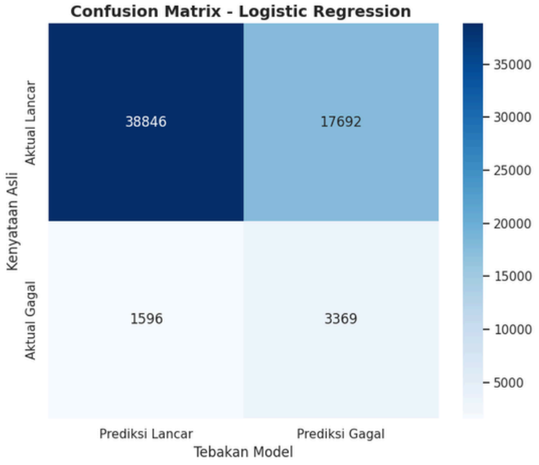

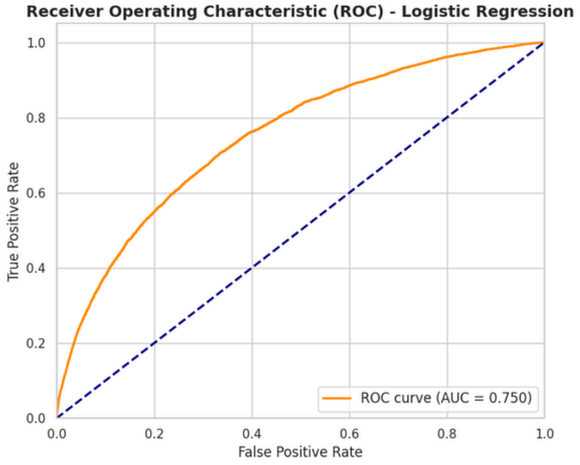

- Kemampuan Deteksi (True Positives): Berhasil memprediksi dengan tepat 3.369 / 4.965 (68%) nasabah yang aktualnya gagal bayar.
- Penolakan Keliru (False Positives): Menghasilkan 17.692 prediksi gagal bayar pada nasabah yang aktualnya berstatus lancar.
- ROC-AUC = 0.750, menunjukkan kemampuan dasar model dalam memisahkan risiko nasabah.

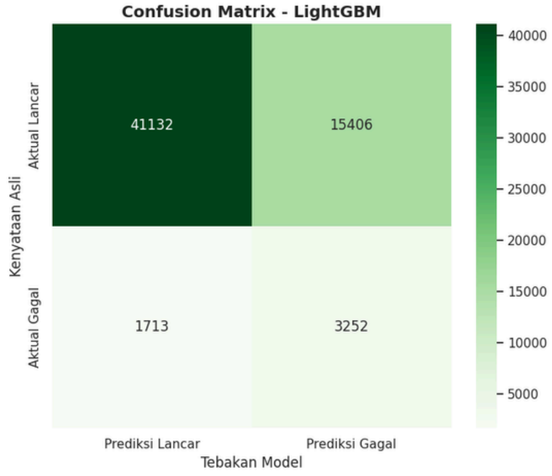

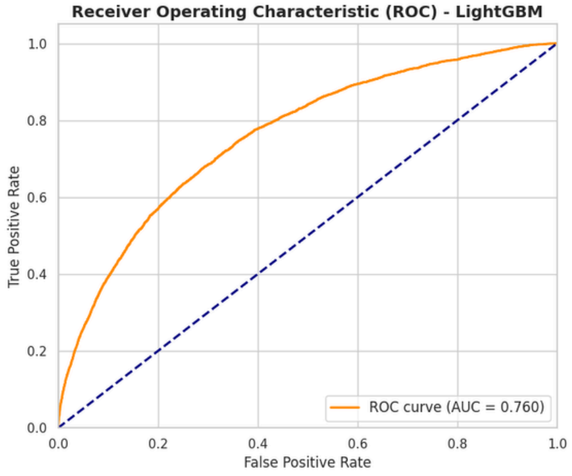

- Kemampuan Deteksi (True Positives): Berhasil memprediksi dengan tepat 3.252 / 4.965 (65%) nasabah yang aktualnya gagal bayar.
- Penolakan Keliru (False Positives): Menghasilkan 15.406 prediksi gagal bayar pada nasabah yang aktualnya berstatus lancar.
- ROC-AUC = 0.760, menunjukkan kemampuan model yang baik dalam membedakan risiko nasabah.

Jadi meskipun Logistic Regression sedikit lebih sensitif dalam mendeteksi risiko, LightGBM lebih direkomendasikan. Model ini menukarkan risiko kecil berupa 117 tambahan nasabah macet (False Negatives) demi menyelamatkan 2.286 nasabah lancar potensial (False Positives) dari penolakan keliru. Secara bisnis, trade-off ini jauh lebih menguntungkan untuk meningkatkan revenue.

Data Visualization and Business Insight

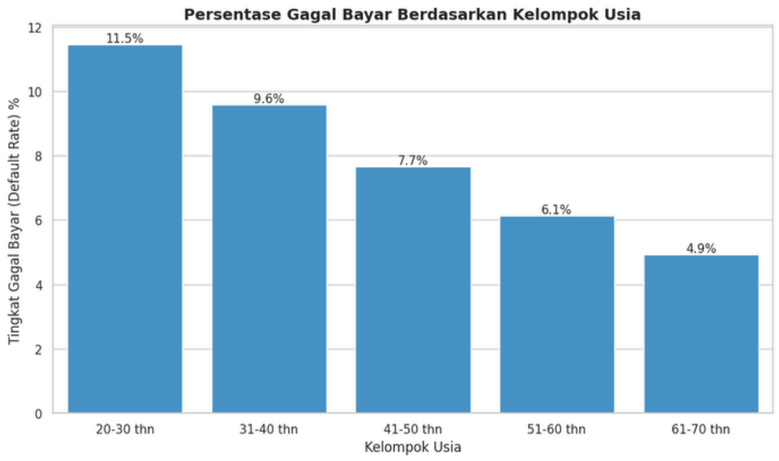

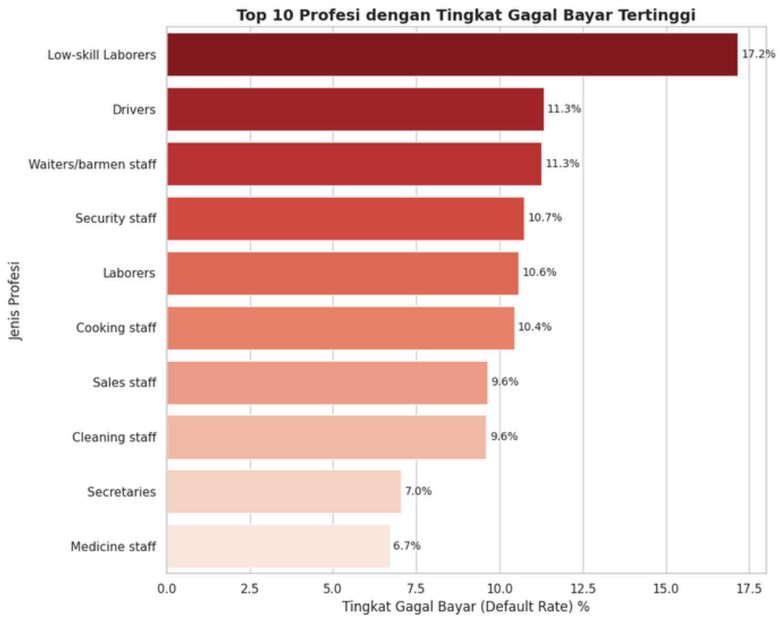

Insight Data

- Nasabah usia 20–30 tahun memiliki risiko gagal bayar tertinggi (±11.5%) dan menurun seiring usia (61–70 tahun: ±4.9%).
- Pekerja berisiko tinggi: Low-skill laborers (17.2%), drivers (11.3%), dan waiters/barmen (11.3%) → rentan karena arus kas tidak stabil.
- Rekomendasi 1 (Risk Control): Perketat underwriting atau minta jaminan tambahan untuk nasabah muda dengan pekerjaan berisiko tinggi.
- Rekomendasi 2 (Strategi Produk):
  - Terapkan product customization → mulai dari plafon kecil & tenor pendek (micro-loans)
  - Naikkan limit bertahap jika riwayat pembayaran baik
  - Gunakan skor eksternal (EXT_SOURCE) sebagai filter utama agar tetap adil bagi nasabah potensial

Feature Importance

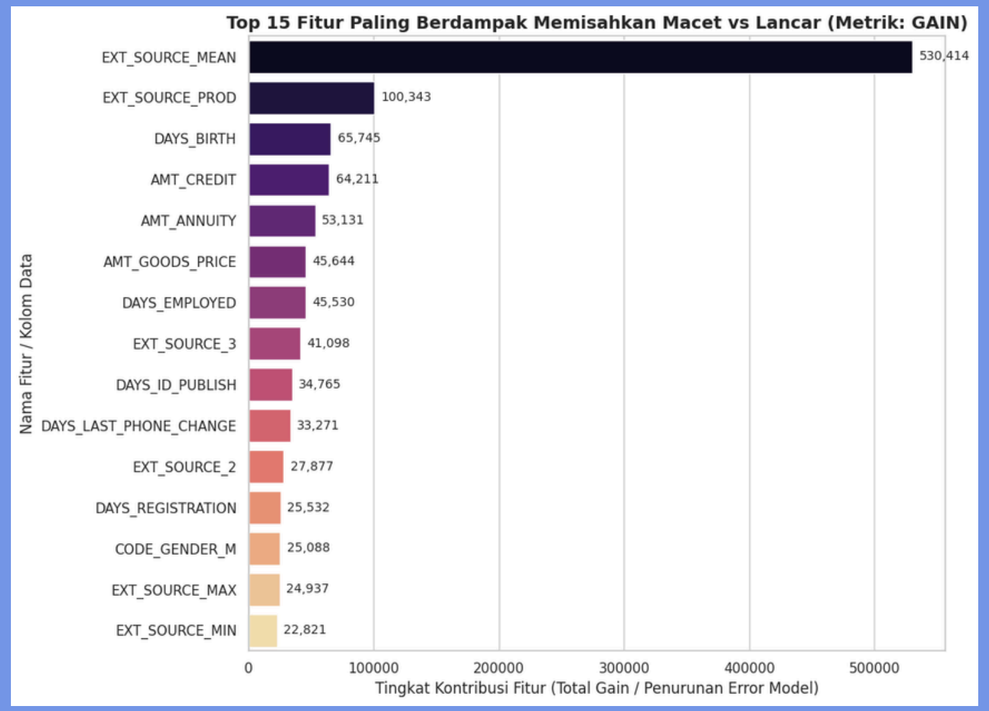

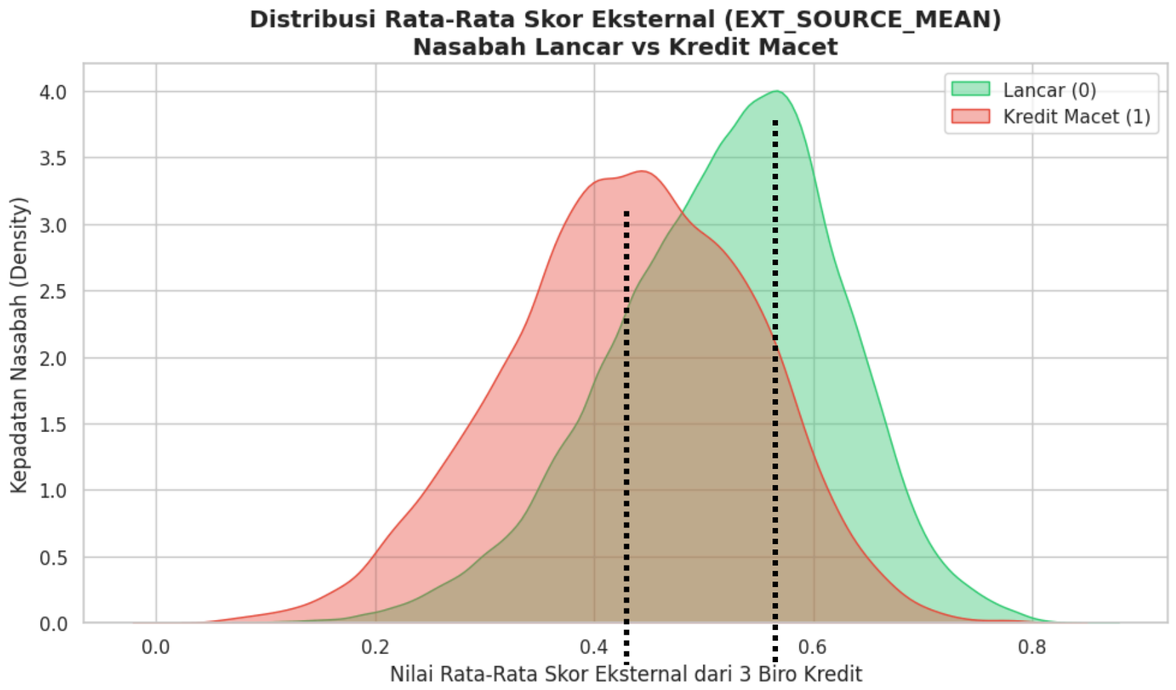

Insight Data

- **Pendekatan Metrik GAIN**: Menggunakan metrik evaluasi Gain (Dampak Penurunan Error) untuk mengatasi bias pada data yang timpang (Imbalanced Dataset).
- **Validasi Pihak Ketiga sebagai Kunci**: Skor dari biro kredit eksternal (**EXT_SOURCE_MEAN**), **yaitu rata-rata rekam jejak** atau 'rapor' **pinjaman nasabah di lembaga keuangan lain** , terbukti menjadi prediktor paling berdampak dibandingkan faktor dasar seperti umur atau gaji.
  -

- Ambang Batas Risiko (**Risk Threshold**): **Puncak kepadatan nasabah gagal bayar** (area merah) **terpusat di rentang skor yang lebih rendah** (puncak di sekitar 0.43). Sebaliknya, **populasi nasabah lancar** (area hijau) bergeser ke kanan dan **mendominasi zona skor yang lebih tinggi** (puncak di sekitar 0.57).

Kesimpulan:
Berdasarkan data Rapor kredit eksternal (EXT_SOURCE_MEAN) adalah prediktor risiko paling akurat: **Semakin rendah skor eksternalnya, semakin condong nasabah tersebut untuk gagal bayar (macet).**

Business Recommendation

- **Optimalisasi Filter Utama**: **Gunakan skor biro kredit eksternal** (EXT_SOURCE_MEAN) **sebagai penentu utama persetujuan kredit**, menggantikan dominasi faktor profil seperti usia dan gaji.
- **Product Customization & Tiering**: Berikan pinjaman awal yang kecil (micro-loans) dengan tenor pendek, lalu naikkan limit secara bertahap jika riwayat pembayarannya disiplin untuk nasabah berisiko (usia 20-30 thn & pekerja kerah biru).
- **Maksimalkan Revenue (LightGBM)**: Implementasikan model LightGBM terbukti menekan False Positives lebih baik dibandingkan Logistic Regression, mengurangi kekeliruan sistem dalam menolak ribuan nasabah potensial.

Future Works

- **Ekstraksi Data Perilaku** (Behavioral): **Mengolah tabel sekunder** (installments_payments.csv) u**ntuk mendapatkan fitur rekam jejak cicilan masa lalu**, seperti rata-rata hari keterlambatan (Days Past Due).
- **Segmentasi Model** (Clustering): **Membangun model spesifik yang dipisahkan berdasarkan profil nasabah** (misal: first-time borrower vs nasabah berpengalaman) agar penilaian lebih adil.
- **Advanced Ensembling**: Menggabungkan kelebihan dari beberapa algoritma sekaligus (LightGBM, XGBoost, Neural Network) menggunakan metode Stacking untuk memaksimalkan akurasi.

Fauget

Thank You Very Much

Penerapan lengkap dapat diakses pada:
https://github.com/niqanabila16/Credit-Score-Prediction